머신러닝

2주차. Scikit-Learn

학습 목표

- Scikit-Learn 소개 및 설치
- Scikit-Learn 주요 모듈
- Scikit-Learn 사용 방법 및 순서
- 실습데이터
  - 붓꽃(Iris) 데이터셋
  - Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기

Scikit-Learn

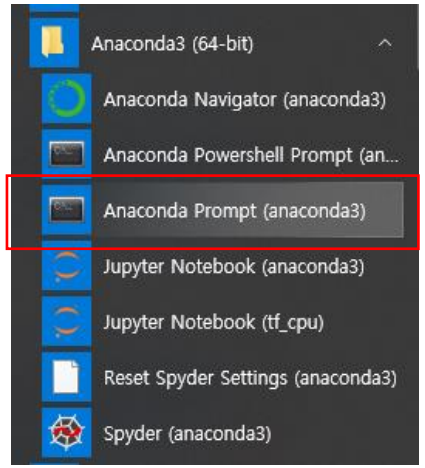
- **Scikit-Learn 소개**
  - 파이썬 기반의 머신러닝 라이브러리
  - 머신러닝을 위한 매우 다양한 알고리즘과 개발을 위한 편리한 프레임워크 및 API 제공
  - 간단하고 효율적으로 **데이터 분석, 예측 모델 구축** 등을 할 수 있게 도와주는 도구
  - 오랜 기간 실전 환경에서 검증되었으며, 매우 환경에서 사용
  - 주로 Numpy, Scipy, Matplotlib 기반 위에서 구축된 라이브러리

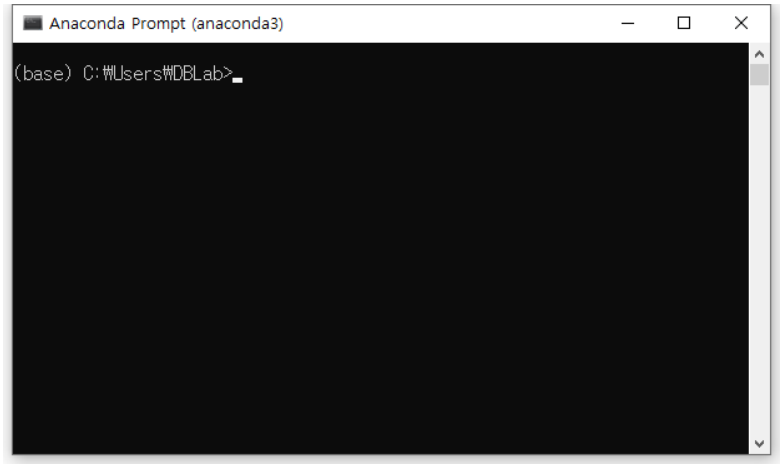
- **Scikit-Learn 장점**
  - 간편한 사용
  - 풍부한 알고리즘
  - 강력한 문서화
  - Numpy, Pandas등 라이브러리와 연동 용이
  - Mnist 데이터, 보스턴 주택가격, 붓꽃 데이터 등 테스트 샘플 데이터 제공

https://scikit-learn.org/

Scikit-Learn 설치

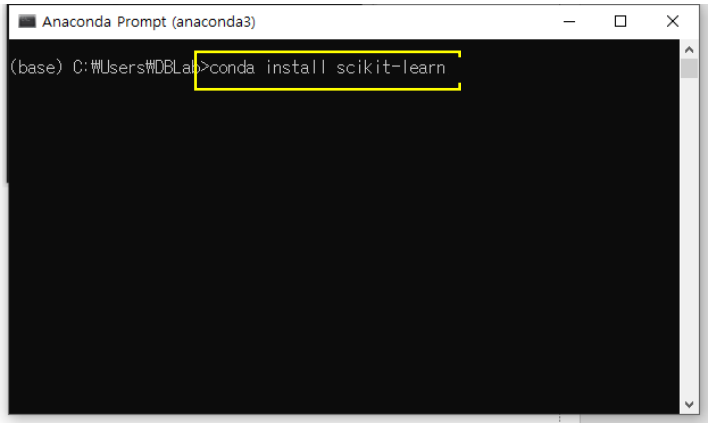
- **Anaconda Prompt 실행**
  - 패키지를 설치할 가상환경 활성화





- **Prompt 창에 명령어 입력**

```
>conda install scikit-learn
```

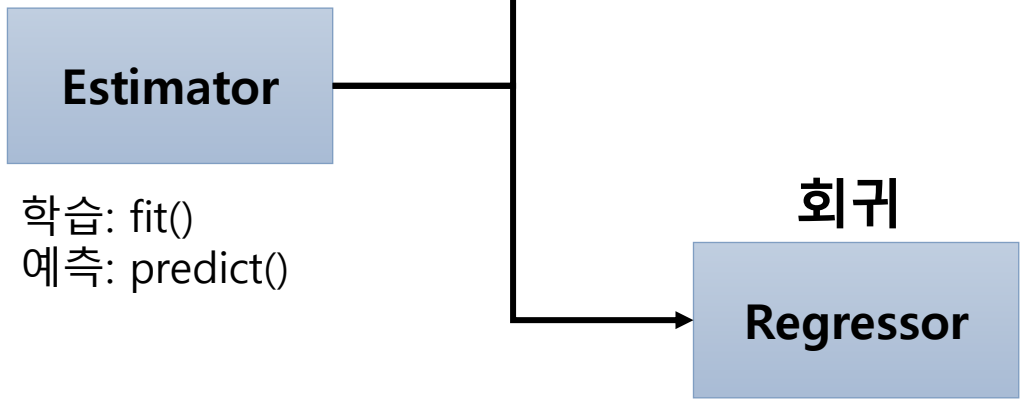


Scikit-Learn

- **기계학습 알고리즘**

적용 분야	설명
분류 (Classification)	SVM, k-NN, 랜덤 포레스트 등 다양한 알고리즘 지원
회귀 (Regression)	선형 회귀, 릿지 회귀 등 회귀 분석 모델 제공
클러스터링 (Clustering)	K-Means, DBSCAN 등 비지도 학습 기반 군집화
차원 축소 (Dimensionality Reduction)	PCA, t-SNE 등 고차원 데이터 시각화 및 압축
모델 선택 (Model Selection)	교차 검증, Grid Search 등 하이퍼파라미터 튜닝 도구 제공
전처리 (PreProcessing)	정규화, 스케일링, 인코딩 등 데이터 전처리 함수 제공

Scikit-Learn의 주요 모듈



분류 구현 클래스

DecisionTreeClassifier
RandomForestClassifier
GradientBoostingClassifier
GaussianNB
SVC

회귀 구현 클래스

LinerRegression
Ridge
Lasso
RandomForestRegressor
GradientBoostingRegressor

Scikit-Learn의 주요 모듈(계속)

분류	모듈명	설명
예제 데이터	**sklearn.datasets**	Scikit-Learn에 내장되어 예제로 제공하는 데이터 세트
데이터 분리, 검증 & 파라미터 튜닝	**sklearn.model_selection**	교차 검증을 위한 학습용/테스트용 분리, 그리드 서치(Grid Search)로 최적 파라미터 추출 등의 API 제공
피처 처리	**sklearn.preprocessing**	데이터 전처리에 필요한 다양한 가공 기능 제공 (문자열을 숫자형 코드 값으로 인코딩, 정규화, 스케일링 등)
	sklearn.feature_selection	알고리즘에 큰 영향을 미치는 피처를 우선순위대로 셀렉션 작업을 수행하는 다양한 기능 제공
	sklearn.feature_extraction	텍스트 데이터나 이미지 데이터의 벡터화된 피처를 추출 예를 들어 텍스트 데이터에서 Count Vectorizer나Tf-Idf Vectorizer 등을 생성하는 기능 제공 텍스트 데이터의 피처 추출은 sklearn.feature_extraction.text 모듈에, 이미지 데이터의 피처 추출은 sklearn.feature_extraction.image 모듈에 지원 API가 있음
피처 처리 & 차원 축소	**sklearn.decomposition**	차원 축소와 관련한 알고리즘을 지원하는 모듈 PCA, NMF, Truncated SVD 등을 통해 차원 축소 기능을 수행

Scikit-Learn의 주요 모듈(계속)

분류	모듈명	설명
평가	sklearn.metrics	분류, 회귀, 클러스터링, 페어와이즈(Pairwise)에 대한 다양한 성능 측정 방법 제공 Accuracy, Precision, Recall, ROC-AUC, RMSE 등 제공
ML 알고리즘	sklearn.ensemble	앙상블 알고리즘 제공 랜덤 포레스트, 에이다 부스트, 그래디언트 부스팅 등을 제공
	sklearn.linear_model	주로 선형 회귀, 릿지(Ridge), 라쏘(Lasso) 및 로지스틱 회귀 등 회귀 관련 알고리즘을 지원. 또한 SGD(Stochastic Gradient Desccent) 관련 알고리즘도 제공
	sklearn.naïve_bayes	나이브 베이즈 알고리즘 제공. 가우시안 NB. 다항 분포 NB 등
	sklearn.neighbors	최근접 이웃 알고리즘 제공. K-NN(K-Nearest Neighborhood) 등
	sklearn.svm	서포트 벡터 머신 알고리즘 제공
	sklearn.tree	의사 결정 트리 알고리즘 제공
	sklearn.cluster	비지도 클러스터링 알고리즘 제공 (K-평균, 계층형, DBSCAN 등)
유틸리티	sklearn.pipeline	피처 처리 등의 변환과 ML 알고리즘 학습, 예측 등을 함께 묶어서 실행할 수 있는 유틸리티 제공

Scikit-Learn의 주요 모듈(계속)
- Scikit-Learn 내장 예제 데이터 셋: 분류 및 회귀용

API명	설명	학습 용도
datasets.load_boston()	미국 보스턴의 집 피처들과 가격에 대한 데이터 세트	회귀
datasets.load_breast_cancer()	위스콘신 유방암 피처들과 악성/음성 레이블 데이터 세트	분류
datasets.load_diabetes()	당뇨 데이터 세트	회귀
datasets.load_digits()	0~9까지의 숫자 이미지 픽셀 데이터 세트	분류
datasets.load_iris()	붓꽃에 대한 피처를 가진 데이터 세트	분류

Scikit-Learn 사용 방법 및 순서

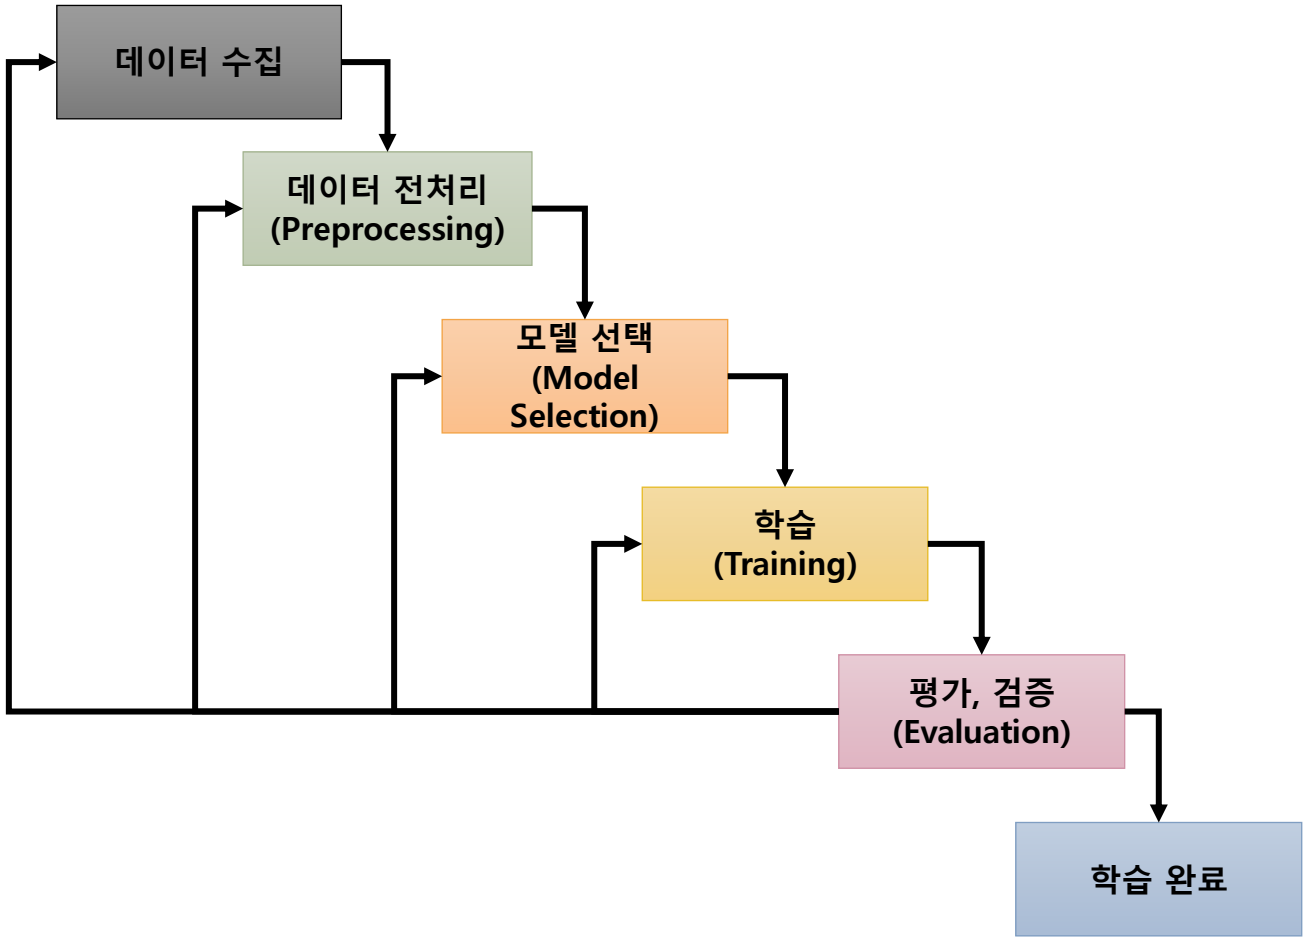
- **데이터 수집**
  - 해결하고자 하는 문제를 정의하고
  - 관련 된 데이터 수집(공개 데이터, 웹 크롤링, 로그 데이터 수집 등)
  - 수집된 데이터(10) = 학습 데이터(7) + 검증 데이터(3)

- **데이터 전처리**
  - 수집된 데이터를 학습에 적용하기 위한 형태로 변형
  - 불필요한 요소 또는 중복 제거, 데이터 누락 여부 확인 등
  - 데이터 정제라고도 부름

- **모델 선택**
  - 학습 방법과 알고리즘 선택
  - 데이터의 성격에 따라 지도학습, 비지도학습, 강화학습 모델

- **학습**
  - 주어진 데이터들을 기반으로 선택한 모델로 학습
  - 학습 데이터(Training Data) 사용

- **평가 및 검증**
  - 검증 데이터(Test Data)사용
  - 학습 결과를 평가하여 성능 검증
  - 결과에 따라 모델의 알고리즘 또는 조건을 변경하고 다시 학습



Scikit-Learn 사용 방법 및 순서(계속)

- **데이터 로드 및 준비**
  - 학습 데이터(Training Data): 입력 값, 출력 값
  - 검증 데이터(Test Data): 입력 값 , 출력 값
- **모델 객체 생성 및 학습**
  - ML 알고리즘 선택
  - fit() 함수: 학습데이터를 함수의 입력 값으로 받음
- **결과 예측**
  - predict()함수: 검증 데이터를 함수의 입력 값으로 받음
- **평가**
  - Metrics 모듈: accuracy_score() 함수 활용
  - predict()함수를 통해 예측된 결과 값을 검증데이터의 출력 값과 비교해 줌

Scikit-Learn 사용 방법 및 순서(계속)

- **특성(Feature)**
  - 학습 모델에게 학습을 위해 주어지는 입력 값(Input data)
  - 모델이 예측을 수행하기 위해 입력받는 데이터의 속성 또는 변수등의 일반 속성 값
  - 학습 데이터에서 독립변수(Independent Variable)의 역할을 하며, Target 값을 예측하기 위한 기준이 되는 정보

- **타겟/레이블/클래스/정답(Target/Label/Class)**
  - 머신러닝 모델이 예측하고자 하는 결과값 또는 출력값(Output data)
  - 학습 데이터에서 종속 변수(Dependent Variable)로서 Feature를 기반으로 모델이 학습하여 도출해내려는 값
  - 타겟은 문제의 종류에 따라 분류(classification), 회귀(regression) 등 다양한 형태로 적용

Scikit-Learn 사용 방법 및 순서(계속)

- 특성과 타겟의 예시

No.	특성(Feature) (문제)		타겟(Target) (정답)	
	키(cm)	몸무게(kg)	비만 여부	레이블(Label)
1	160	48	아니오	0
2	170	65	아니오	0
3	165	85	예	1
4	180	90	예	1
5	175	70	아니오	0
6	158	60	예	1
7	168	55	아니오	0
8	172	80	예	1
9	169	67	아니오	0
10	182	75	아니오	0

실습데이터
- 붓꽃(Iris) 데이터셋

- **붓꽃(Iris) 데이터셋**
  - 1936년 통계학자 Ronald A. Fisher가 논문에서 사용한 붓꽃 꽃잎과 꽃받침의 크기를 측정한 고전 데이터셋
  - 머신러닝과 통계학에서 가장 널리 사용되는 (입문용)분류 문제 데이터셋
  - 프랑스의 국화로 꽃받침(Sepal)과 꽃잎(Petal)의 크기로 3개의 품종으로 구분됨
  - **3개 품종 분류 문제에 활용**

항목	설명
데이터 수	총 150개 샘플
클래스	3개 (setosa, versicolor, virginica)
특성 개수	4개
문제 유형	다중 클래스 분류

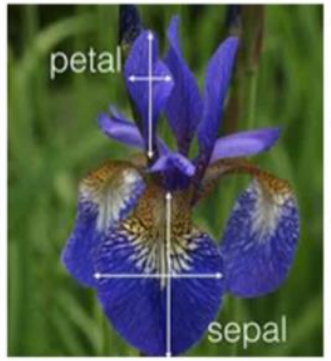


Ronald Aylmer Fisher(1890~1962)
영국 수학자, 통계학자
생물학자, 유전학자

실습데이터
- 붓꽃(Iris) 데이터셋(계속)

- **붓꽃(Iris) 데이터셋 특징(Feature)**
  - Sepal Length (꽃받침 길이, cm)
  - Sepal Width (꽃받침 너비, cm)
  - Petal Length (꽃잎 길이, cm)
  - Petal Width (꽃잎 너비, cm)

붓꽃 데이터 피처



- Sepal length
- Sepal width
- Petal length
- Petal width

- **붓꽃(Iris) 데이터셋 타겟/레이블(Target/Label)**
  - Setosa (0)
  - Versicolor (1)
  - Virginica (2)

붓꽃 데이터 품종(레이블)

Setosa



Vesicolor



Virginica



실습데이터
- 붓꽃(Iris) 데이터셋(계속)

- **Fisher의 붓꽃 데이터**
  - CSV(Comma-Separated Values) 형태
  - 150개의 데이터

입력 데이터 (Feature) | **출력 데이터 (Target_name)**

	SepalLength	SepalWidth	PetalLength	PetalWidth	Name
2	5.1	3.5	1.4	0.2	Iris-setosa
3	4.9	3	1.4	0.2	Iris-setosa
4	4.7	3.2	1.3	0.2	Iris-setosa
5	4.6	3.1	1.5	0.2	Iris-setosa
6	5	3.6	1.4	0.2	Iris-setosa
7	5.4	3.9	1.7	0.4	Iris-setosa
8	4.6	3.4	1.4	0.3	Iris-setosa
9	5	3.4	1.5	0.2	Iris-setosa
10	4.4	2.9	1.4	0.2	Iris-setosa

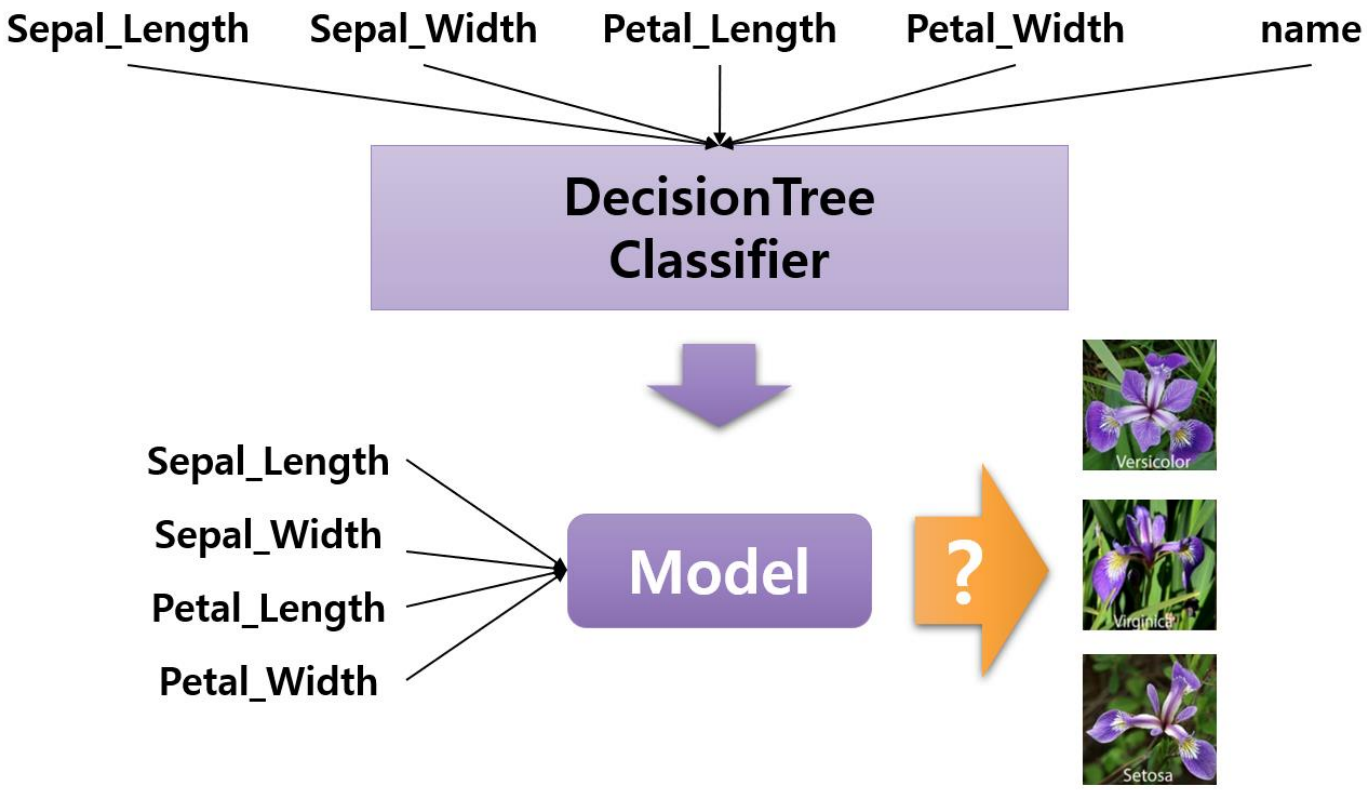
⋮

150

https://gist.github.com/netj/8836201#file-iris-csv

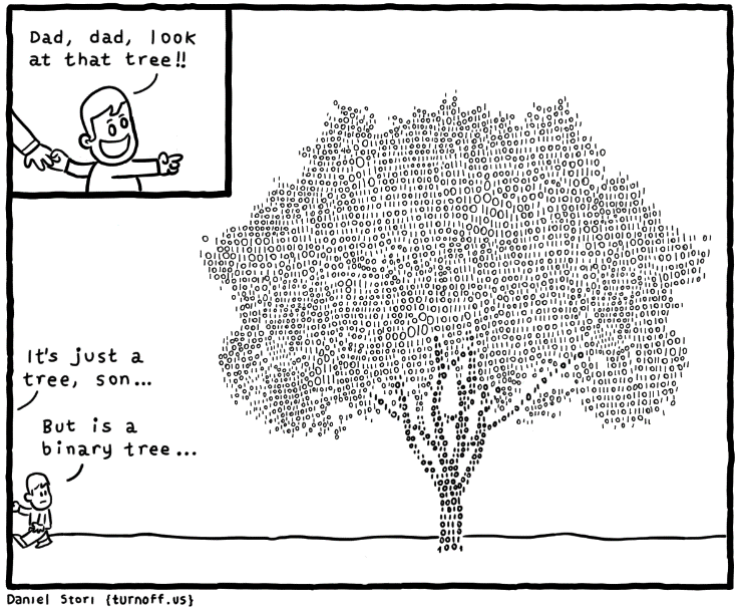
실습데이터
- Scikit-Learn을 이용한 학습

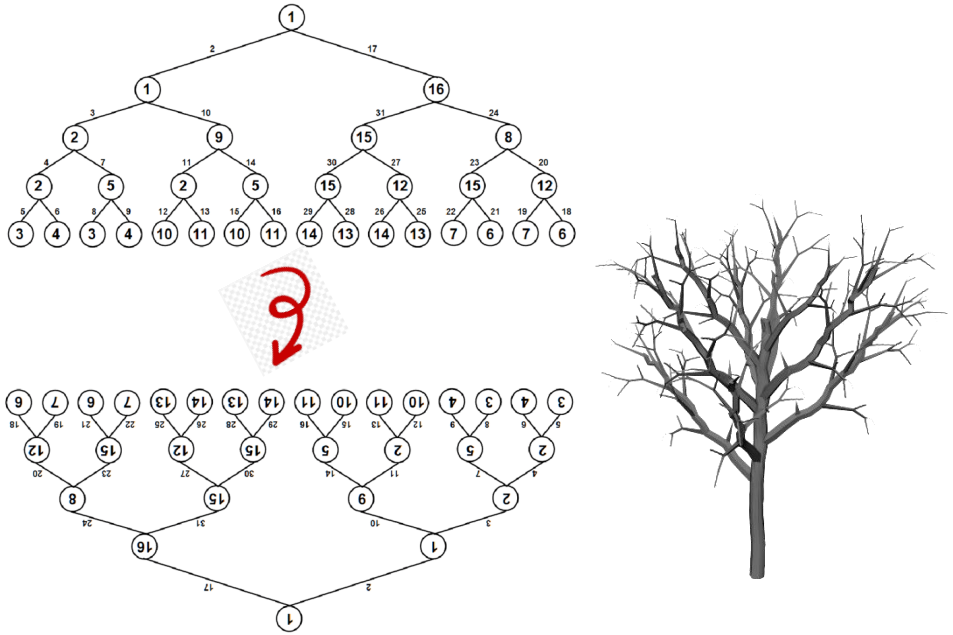
- **분류 방법**
  - 붓꽃 데이터 세트의 꽃잎의 길이와 너비, 꽃받침의 길이와 너비 특징(Feature)를 기반으로 품종 예측



실습데이터
- Scikit-Learn을 이용한 학습(계속)

- **의사 결정 트리 개념(Decision Tree)**
  - 데이터에 있는 **규칙을 학습**을 통해 자동으로 찾아내 **트리 (Tree)기반의 분류 규칙**을 만드는 것
  - 지도 학습 모델 중 하나이며 일련의 **분류 규칙을 통해 데이터를 분류 회귀에 적용**됨
  - 결과 모델이 나무(Tree)구조를 띄며, 결정트리, 의사결정나무 등으로 지칭



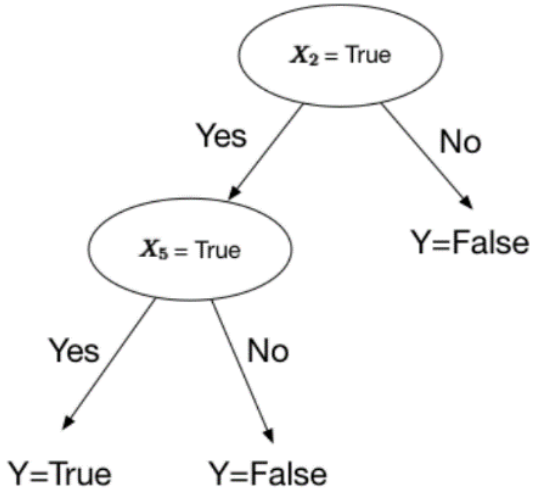


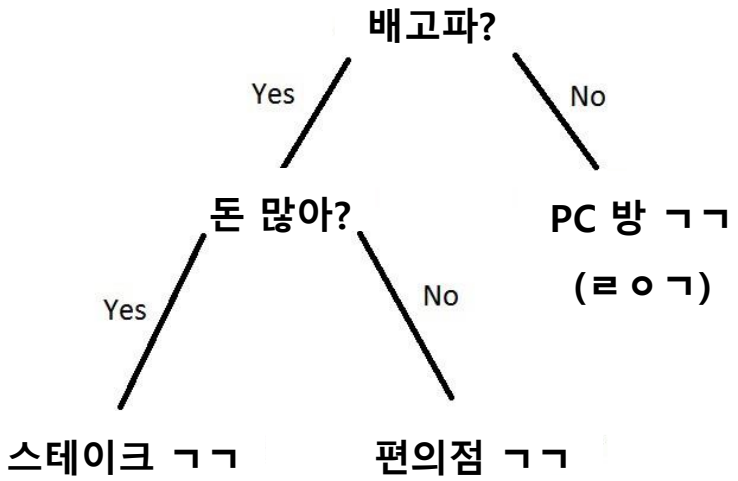
실습데이터
- Scikit-Learn을 이용한 학습(계속)

- **의사 결정 트리(Decision Tree)**
  - 1986년 로스 퀸란(Ross. Quinlan) 발표
  - 관측 값과 목표 값을 연결하는 예측 모델
  - 학습데이터를 가지고 여러 가지 **결정(Decision)**을 통해 **이진 트리를 구성**
  - '스무고개' 문답처럼 선택 방법으로 진행



로스 퀸란
(Ross Quinlan)

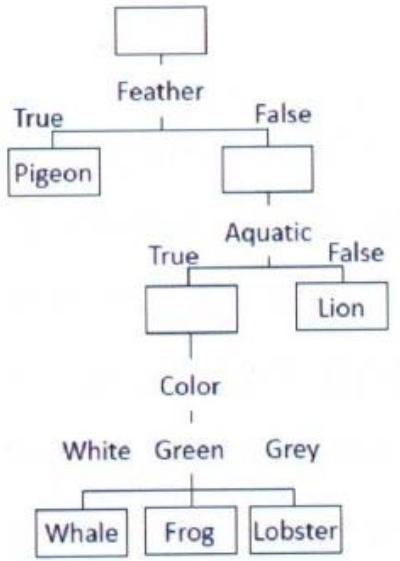


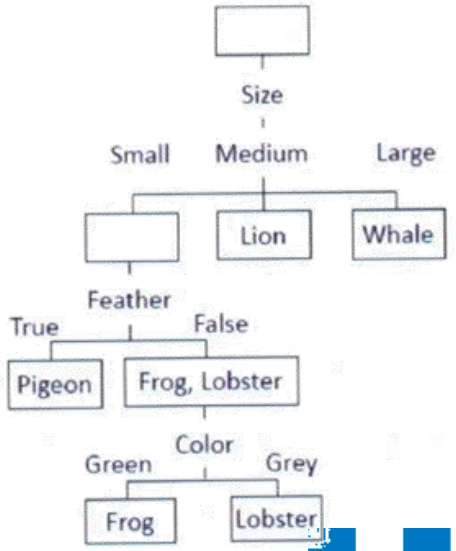


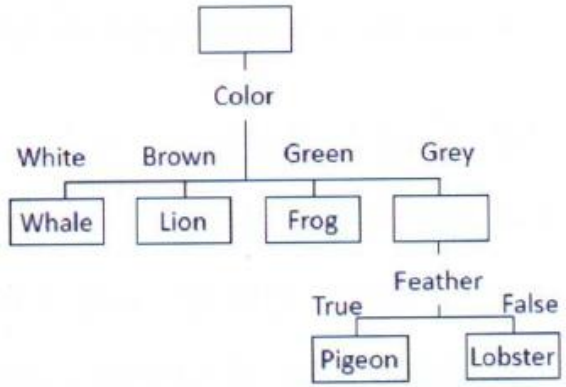
실습데이터
- Scikit-Learn을 이용한 학습(계속)

- 분기 속성 선정의 중요성

No.	Milk	Feather	Aquatic	Egg	Legs	Size	Color	Animal
1	True	False	True	False	False	Large	White	Whale
2	True	False	False	False	True	Medium	Brown	Lion
3	False	False	True	True	True	Small	Green	Frog
4	False	True	False	True	True	Small	Grey	Pigeon
5	False	False	True	True	True	Small	Grey	Lobster







실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기

- **sklearn 버전 확인 및 패키지 import**

```
1 import sklearn
2 print(sklearn.__version__)
```

```
1.0.2
```

버젼확인

붓꽃데이터셋 가져오기

```
1 from sklearn.datasets import load_iris
2 from sklearn.tree import DecisionTreeClassifier
3 from sklearn.model_selection import train_test_split
```

모델 가져오기
결정트리 분류모델

데이터를
학습/테스트로 나누는 API

실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- 붓꽃 데이터 세트 로딩 및 pandas DataFrame 변환

pandas import

```
1  import pandas as pd
2
3  # 붓꽃 데이터 세트를 로딩합니다.
4  iris = load_iris()
5
6  # iris.data는 Iris 데이터 세트에서 피처(feature)만으로 된 데이터를 numpy로 가지고 있습니다.
7  iris_data = iris.data
8
9  # iris.target은 붓꽃 데이터 세트에서 레이블(결정 값) 데이터를 numpy로 가지고 있습니다.
10 iris_label = iris.target
11 print('iris target값:', iris_label)
12 print('iris target명:', iris.target_names)
13
14 # 붓꽃 데이터 세트를 자세히 보기 위해 DataFrame으로 변환합니다.
15 iris_df = pd.DataFrame(data=iris_data, columns=iris.feature_names)
16 iris_df['label'] = iris.target
17 iris_df.head(3)
```

데이터 로딩

❶ ❷

DataFarame 변환
데이터: iris_data (특징데이터)
컬러명: iris_feature_name(특징이름)

❸

컬럼명 'label' 추가
컬럼값: 타겟값(숫자)

iris

iris.data = 특징 데이터(문제)
iris.target = 타겟 값(숫자_정답)
iris_feature_name = 특징 이름
iris.target_name = 레이블 이름

실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- 붓꽃 데이터 세트 로딩 및 pandas DataFrame 변환 결과

❶
```
iris target값: [0 0 0 
```

실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- 붓꽃 데이터 학습/테스트 데이터 분리
  - train_test_split()

학습용(train)

특징 데이터 타겟 데이터

```
1  X_train, X_test, y_train, y_test = train_test_split(iris_data, iris_label,
2                                                      test_size=0.2, random_state=11)
```

테스트용(test)

테스트 데이터 비율
학습 : 테스트 = 8 : 2
(150개 -> 120: 30)

학습데이터/테스트데이터 분리

X_train: 학습용 특징데이터(문제)
X_test: 테스트용 특징데이터(문제)

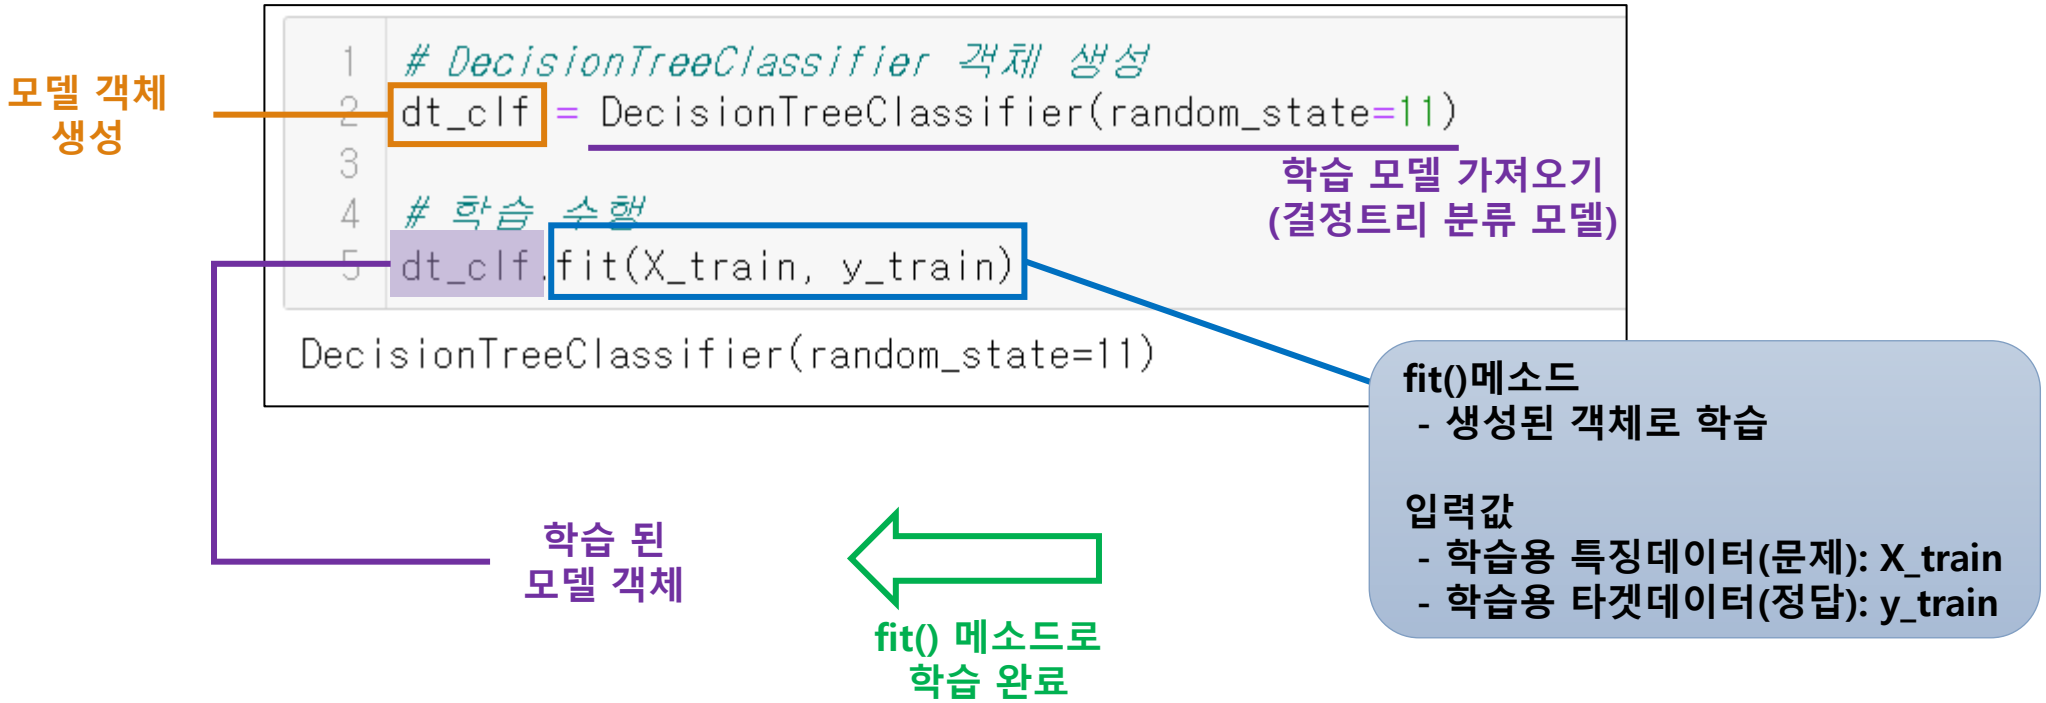
y_train: 학습용 타겟데이터(정답)
y_test: 테스트용 타겟데이터(정답)

train_test_split()

```
train_test_split(
    *arrays,
    test_size=None,
    train_size=None,
    random_state=None,
    shuffle=True,
    stratify=None,
)
```

실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- **학습 데이터 세트로 학습(Train) 수행**
  1. 학습하고자 하는 모델 객체 생성
  2. fit()메소드로 데이터 학습 : 학습데이터 (X_train, y_train) 입력 후 학습



실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- **테스트 데이터 세트로 예측(Predict) 수행**
  1. 학습된 모델 객체(dt_clf)에 대한 테스트 데이터(X_test)로 테스트 수행
  2. **predict()메소드**: 학습 모델로 테스터 데이터(X_test)를 입력하여 예측 값(pred) 생성

```
1  # 학습이 완료된 DecisionTreeClassifier 객체에서 테스트 데이터 세트로 예측 수행.
2  pred = dt_clf.predict(X_test)
```

학습 된
모델 객체

학습된 모델(dt_clf)이
테스트용 특징 데이터
가지고 생성된 예측 값

predict()메소드
- 학습 된 모델로 예측 값 생성

입력 값
- 테스트용 특징데이터(문제): X_test

실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

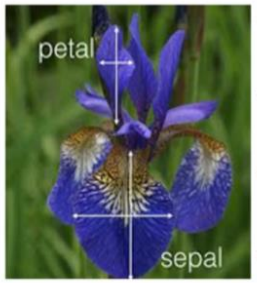
- **테스트 데이터 세트로 예측(Predict) 수행(계속)**

테스트용 특징데이터(문제)
: X_test

```
1 X_test
```

	pred (예측값)
array([[6.8, 3. , 5.5, 2.1],	2
[6.7, 3. , 5.2, 2.3],	2
[6.3, 2.8, 5.1, 1.5],	1
[6.3, 3.3, 4.7, 1.6],	1
[6.4, 2.7, 5.3, 1.9],	2
[4.9, 3.1, 1.5, 0.1],	0
[6.7, 3.1, 4.4, 1.4],	1
[5.7, 4.4, 1.5, 0.4],	0
[4.8, 3.1, 1.6, 0.2],	0

sepal length
sepal width
petal length
petal width



- Sepal length
- Sepal width
- Petal length
- Petal width

학습된 모델(dt_clf)이
테스트용 특징 데이터가지고 생성된 예측 값: pred

```
1 pred
```

```
array([2, 2, 1, 1, 2, 0, 1, 0, 0, 1, 1, 1, 1, 2, 2, 0, 2, 1, 2, 2, 1, 0,
       0, 1, 0, 0, 2, 1, 0, 1])
```

예측된
타겟 레이블

0 Setosa



1 Vesicolor



2 Virginica



실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- **예측 정확도 평가 방식**
  - 학습된 모델로 **예측한 결과 값(pred)**과 **테스트용 타겟 데이터(정답데이터: y_test)**와 비교

```
1 pred
```

```
array([2, 2, 1, 1, 2, 0, 1, 0, 0, 1, 1, 1, 1, 2, 2, 0, 2, 1, 2, 2, 1, 0,
       0, 1, 0, 0, 2, 1, 0, 1])
```

예측 데이터 (pred)

```
1 y_test
```

```
array([2, 2, 2, 1, 2, 0, 1, 0, 0, 1, 2, 1, 1, 2, 2, 0, 2, 1, 2, 2, 1, 0,
       0, 1, 0, 0, 2, 1, 0, 1])
```

정답 데이터 (y_test)

실습데이터
- Scikit-Learn을 이용한 붓꽃(Iris) 데이터 품종 예측하기(계속)

- **예측 정확도 평가**
  - 학습된 모델(dt_clf)의 예측 값이 테스트용 타겟 데이터(실제정답)와 얼마나 일치하는지 평가
  - **accuracy_score() 함수**: 정답 데이터와 예측 값을 비교하여 정확도를 계산

```
1 from sklearn.metrics import accuracy_score
2 print('예측 정확도: {0:.4f}'.format(accuracy_score(y_test,pred)))
```

```
예측 정확도: 0.9333
```

accuracy_score()
함수의 결과 값

accuracy_score() 함수
- 정답과 예측값을 비교하여 정확도를 계산

입력값
- 테스트용 타겟데이터(정답데이터): y_test
- 학습 모델로 예측한 데이터: pred

학습된 모델을 활용한 붓꽃 품종 판별 프로그램

```
붓꽃값(SL, SW, PL, PW)를 입력하여 품종을 알아보도록 하겠습니다.
1. 붓꽃의 '꽃받침 길이(Sepal Length)' 값을 입력해주세요(4~8 사이의 값 입력):  5.1
2. 붓꽃의 '꽃받침 너비(Sepal Witdh)' 값을 입력해주세요(2.0~4.5 사이의 값 입력):  2.5
3. 붓꽃의 '꽃잎 길이(Petal Length)' 값을 입력해주세요(1~7 사이의 값 입력):  6.2
4. 붓꽃의 '꽃잎 너비(Petal Width) 값을 입력해주세요(0.1~2.5 사이의 값 입력):  2.2
[5.1 2.5 6.2 2.2]
당신이 입력한 품종은 'Virginica' 입니다.

============================================================
계속 진행하시겠습니까?(0:종료, 1진행):  1
계속 진행하겠습니다.
붓꽃값(SL, SW, PL, PW)를 입력하여 품종을 알아보도록 하겠습니다.
1. 붓꽃의 '꽃받침 길이(Sepal Length)' 값을 입력해주세요(4~8 사이의 값 입력):  4.1
2. 붓꽃의 '꽃받침 너비(Sepal Witdh)' 값을 입력해주세요(2.0~4.5 사이의 값 입력):  3.7
3. 붓꽃의 '꽃잎 길이(Petal Length)' 값을 입력해주세요(1~7 사이의 값 입력):  3.1
4. 붓꽃의 '꽃잎 너비(Petal Width) 값을 입력해주세요(0.1~2.5 사이의 값 입력):  0.5
[4.1 3.7 3.1 0.5]
당신이 입력한 품종은 'Setosa' 입니다.

============================================================
계속 진행하시겠습니까?(0:종료, 1진행):  1
계속 진행하겠습니다.
붓꽃값(SL, SW, PL, PW)를 입력하여 품종을 알아보도록 하겠습니다.
1. 붓꽃의 '꽃받침 길이(Sepal Length)' 값을 입력해주세요(4~8 사이의 값 입력):  7.5
2. 붓꽃의 '꽃받침 너비(Sepal Witdh)' 값을 입력해주세요(2.0~4.5 사이의 값 입력):  3.6
3. 붓꽃의 '꽃잎 길이(Petal Length)' 값을 입력해주세요(1~7 사이의 값 입력):  5.4
4. 붓꽃의 '꽃잎 너비(Petal Width) 값을 입력해주세요(0.1~2.5 사이의 값 입력):  1.6
[7.5 3.6 5.4 1.6]
당신이 입력한 품종은 'Vesicolor' 입니다.

============================================================
계속 진행하시겠습니까?(0:종료, 1진행):  0
종료하겠습니다
```



강남대학교

KANGNAM UNIVERSITY