머신러닝

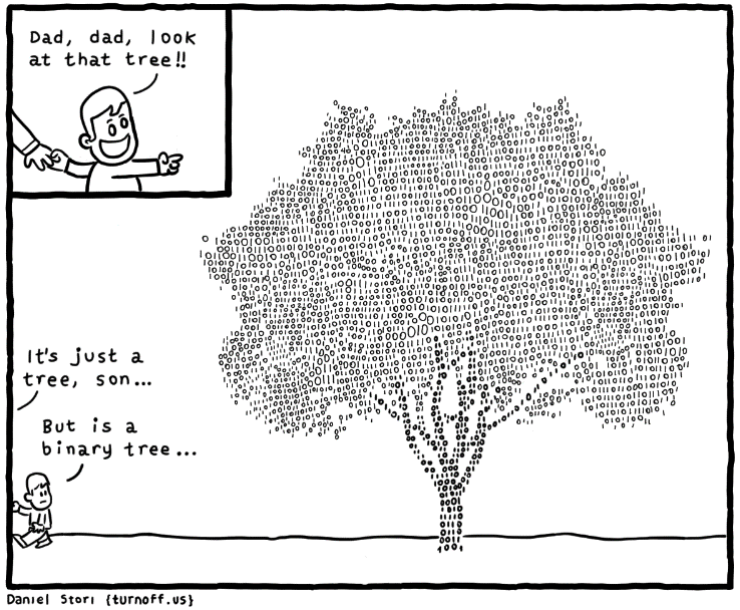
6주차. 결정트리(Decision Tree)

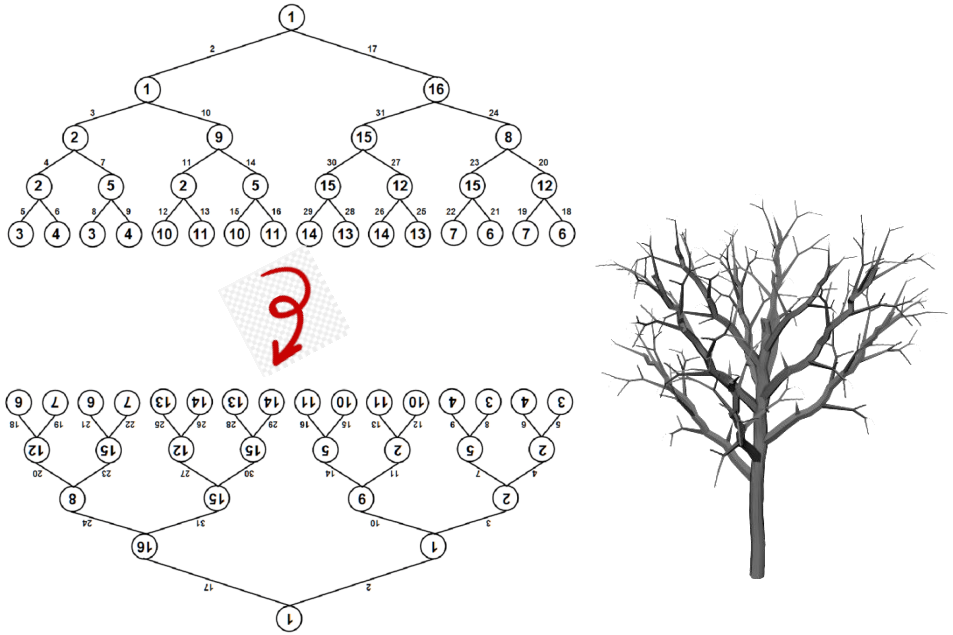
학습 목표

- 의사결정트리 소개
- 의사결정 트리 개념
- ID3
- 지니계수와 CART 알고리즘
- 의사결정 트리의 장단점

의사결정트리

- **의사 결정 트리 개념(Decision Tree)**
  - 데이터에 있는 **규칙을 학습**을 통해 자동으로 찾아내 **트리 (Tree)기반의 분류 규칙**을 만드는 것
  - 지도 학습 모델 중 하나이며 일련의 **분류 규칙을 통해 데이터를 분류 회귀에 적용**됨
  - 결과 모델이 나무(Tree)구조를 띄며, 결정트리, 의사결정나무 등으로 지칭



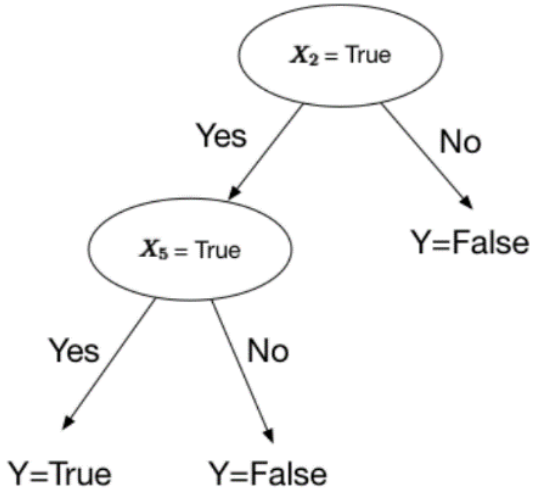


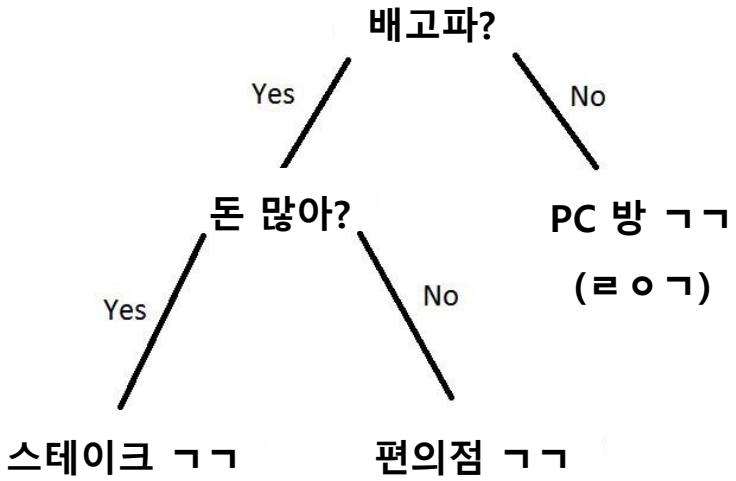
의사결정트리(계속)

- **의사 결정 트리(Decision Tree)**
  - 1986년 로스 퀸란(Ross. Quinlan) 발표
  - 관측 값과 목표 값을 연결하는 예측 모델
  - 학습데이터를 가지고 여러 가지 **결정(Decision)**을 통해 **이진 트리를 구성**
  - '스무고개' 문답처럼 선택 방법으로 진행



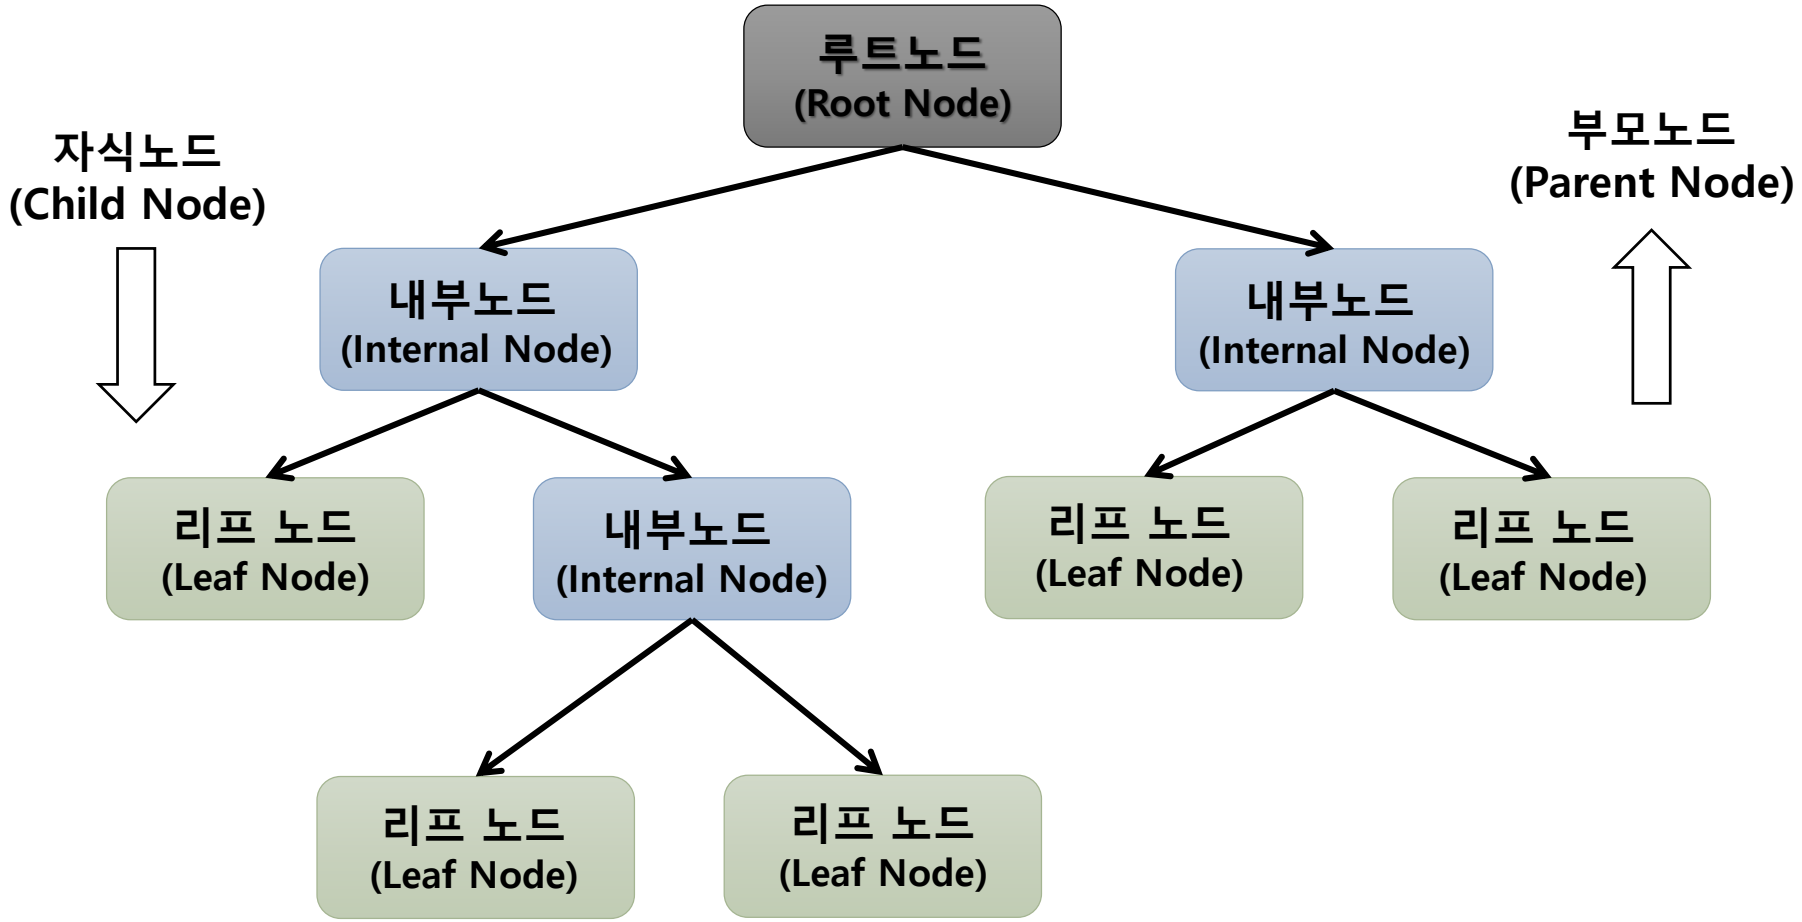
로스 퀸란
(Ross Quinlan)





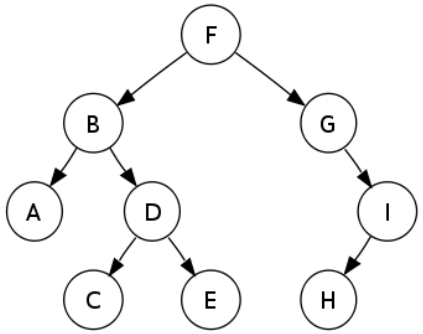
의사결정트리(계속)

- 컴퓨터 공학에서의 트리구조



의사결정트리(계속)

- **노드(Node): 트리의 구성 요소**
  - 루트 노드(root node): 트리가 **시작되는 지점**(뿌리)
  - 부모 노드(Parent Node): 어떤 **노드 바로 위**에 연결된 노드
  - 자식 노드(Child Node): 어떤 **노드의 바로 아래**에 연결된 노드
  - 리프 노드(Leaf Node): **자식 노드가 없는 노드, 단말(Terminal) 노드**라고도 함
  - 형제 노드(Sibling Node): 같은 부모 노드의 자식 노드들
  - 내부 노드(Internal Node): 루트, 리프 노드를 제외한 노드
  - 깊이(Depth): 주어진 트리의 깊이를 뜻하며 값이 클수록 복잡성이 높아짐



- **루트 노드: F**
- **D 노드의 부모노드: B**
- **B 노드의 자식 노드: A, D**
- **D 의 형제 노드: A**
- **내부 노드: B, D, G, I**
- **깊이: 3**

의사결정트리의 개념

- **의사결정트리 생성시 고려사항**
  - **어떤 기준으로 규칙을 만들어야 가장 효율적인 분류가 될 것인가**가 알고리즘 의 성능을 크게 좌우
  - **규칙이 많다는 것**은 좀 더 **예측을 위한 학습이 잘된다고 말할 수 있음**과 **동시에 복잡하다는 의미**
  - 트리의 깊이(depth)가 깊어질 수록 예측 성능이 저하될 가능성이 높기 때문에 적절한 값을 찾는 것이 핵심

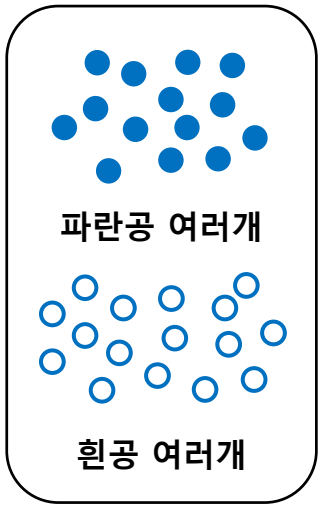
- **분지(Split, 가지 분할)**
  - 의사 결정 트리의 가지를 나누는 것
  - 분지에 의해 데이터 집합이 작은 집합으로 나눠짐
  - 분지에 사용할 데이터의 속성을 잘 활용

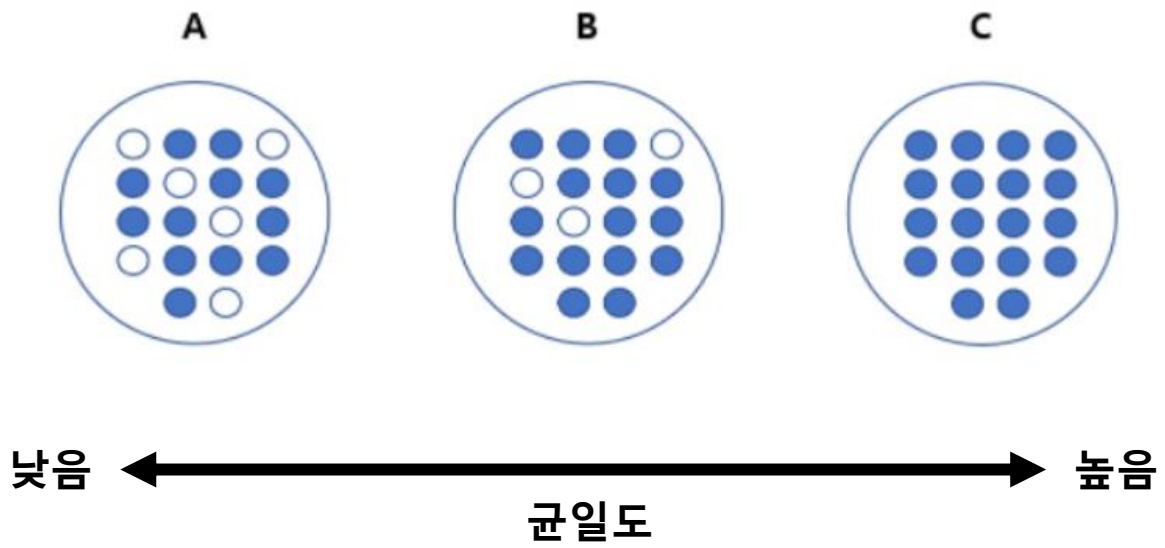


의사결정트리의 개념(계속)

가장 적은 노드로 높은 성능을 보이려면
한번의 분지 시 균일하게 나누어야 함

최대한 **동일한 데이터가 많이 포함**





의사결정트리의 개념(계속)

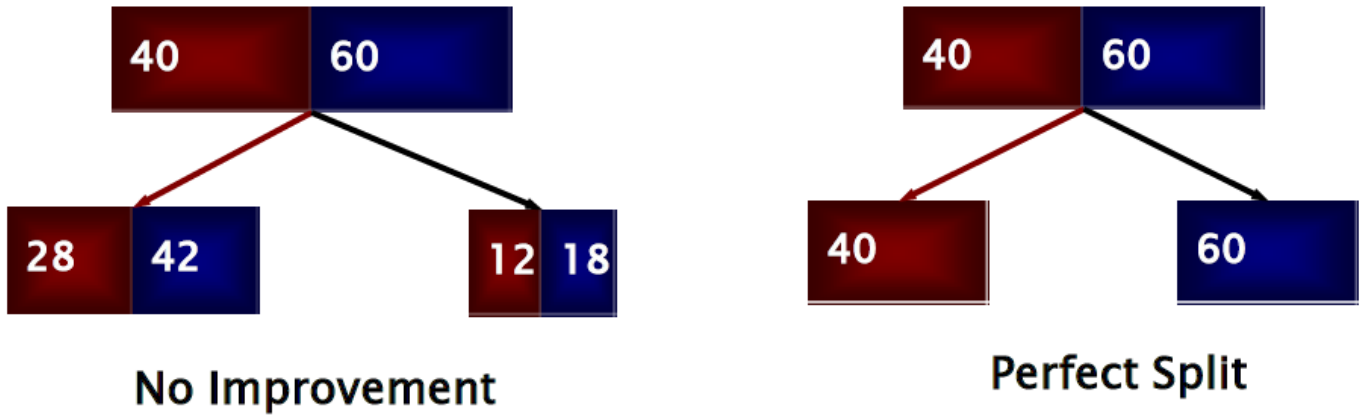
결정 트리 주요 하이퍼 파라미터

파라미터 명	설명
max_depth	• 트리의 최대 깊이를 규정. • 디폴트는 None. None으로 설정하면 완벽하게 클래스 결정 값이 될 때까지 깊이를 계속 키우며 분할하거나 노드가 가지는 데이터 개수가 min_samples_split보다 작아질 때까지 계속 깊이를 증가시킴. • 깊이가 깊어지면 min_samples_split 설정대로 최대 분할하여 과적합할 수 있으므로 적절한 값으로 제어 필요.
max_features	• 최적의 분할을 위해 고려할 최대 피처 개수. 디폴트는 None으로 데이터 세트의 모든 피처를 사용해 분할 수행. • int 형으로 지정하면 대상 피처의 개수, float 형으로 지정하면 전체 피처 중 대상 피처의 퍼센트임 • 'sqrt'는 전체 피처 중 sqrt(전체 피처 개수), 즉 $\sqrt{\text{전체 피처개수}}$ 만큼 선정 • 'auto'로 지정하면 sqrt와 동일 • 'log'는 전체 피처 중 log2(전체 피처 개수) 선정 • 'None'은 전체 피처 선정
min_samples_split	• 노드를 분할하기 위한 최소한의 샘플 데이터 수로 과적합을 제어하는 데 사용됨. • 디폴트는 2이고 작게 설정할수록 분할되는 노드가 많아져서 과적합 가능성 증가 • 과적합을 제어. 1 로 설정할 경우 분할되는 노드가 많아져서 과적합 가능성 증가
min_samples_leaf	• 말단 노드(Leaf)가 되기 위한 최소한의 샘플 데이터 수 • Min_samples_split와 유사하게 과적합 제어 용도. 그러나 비대칭적(imbalanced) 데이터의 경우 특정 클래스의 데이터가 극도로 작을 수 있으므로 이 경우는 작게 설정 필요.
max_leaf_nodes	• 말단 노드(Leaf)의 최대 개수

파이썬 머신러닝 완벽 가이드

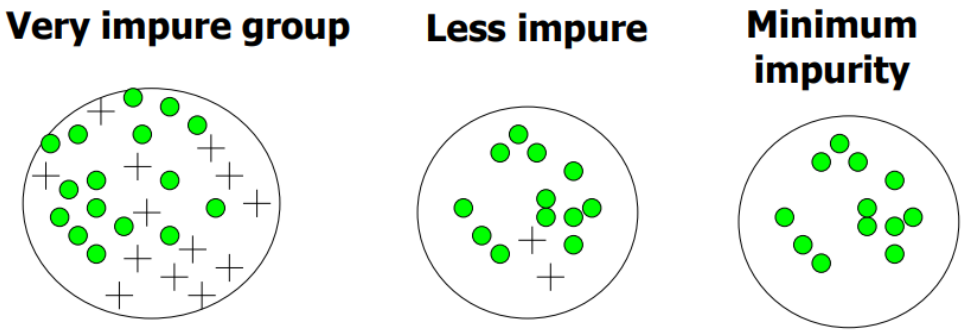
의사결정트리의 개념(계속)

- **결정 트리의 기본 아이디어**
  - 리프노드(Leaf Node)가 **가장 섞이지 않은 상태로 완전히 분류**되는 것
  - 혼잡도가 높고 균일도가 낮을 경우 같은 조건에서 데이터를 판단하는데 있어서 더 **많은 정보가 필요**
  - 규칙이 많으면 그만큼의 새로운 노드들을 거쳐야 한다는 의미
  - 복잡성(entropy)이 낮도록 만드는 것



의사결정트리의 개념(계속)

- **불순도(Impurity)**
  - 복잡성을 의미
  - 해당 범주 안에 서로 다른 데이터가 얼마나 섞여 있는지에 대한 정도
  - 다양한 개체들이 섞여 있을수록 불순도가 상승



  - 현재노드의 불순도에 비해 **자식노드의 불순도가 감소되도록 설정**

의사결정트리의 개념(계속)

- 불순도(Impurity)는 각 클래스의 분포에 근거해 측정

$p(i \mid d)$: 노드 d에서 클래스 i에 속하는 값의 비율
$= p(i)$



Node 1

$$p(red \mid 1): \frac{10}{16} = 0.625$$

$$p(blue \mid 1): \frac{6}{16} = 0.375$$

ID3

- **ID3(Iterative Dichotomiser 3)**
  - 로스 퀸란의 결정트리 알고리즘로 결정 트리의 초창기 모델
  - Dichotomiser는 "이분하다"라는 뜻의 프랑스어로, 반복적으로 이분하는 알고리즘
  - 정보이론의 정보량과 **엔트로피(Entropy)**로 불순도를 계산

- **ID3의 결정트리 생성 방법**

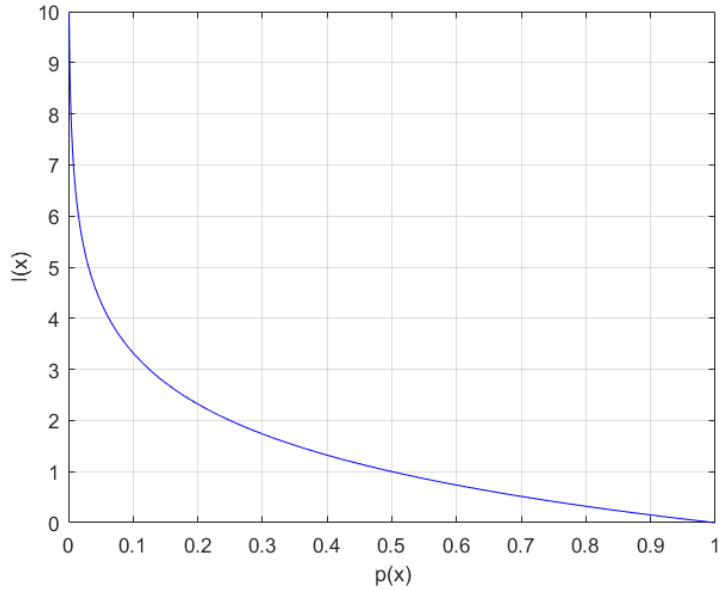
1. **루트 노드 생성**

2. **현재 생성된 트리에서 모든 단말 노드는 아래를 반복**
   - **정보이득(Information Gain)이 높은 속성을 선택해서 노드 분할**
   - **해당노드의 데이터들이 동일 클래스이면 종료**
   - **더 이상 사용할 수 있는 속성이 없으면 종료**

ID3(계속)

- **정보량(Information)**
  - 어떤 사건이 가지고 있는 정보의 양
  - 드물게 발생하는 일일수록 정보량이 큼
  - $p(x)$는 사건 x 가 발생할 확률
    - 1에 가까울수록 정보량 0에 가까워 짐(흔하게 발생)
    - 0에 가까울수록 정보량은 무한히 커짐(어쩌다 발생)

$$I(x) = log_2 \frac{1}{p(x)}$$



ID3(계속)

- **엔트로피(Entropy)**
  - **불순도를 수치적으로 측정하여 나타내는 지표**
  - 정보량의 기댓값(평균)
  - 엔트로피가 **높으면 불순도가 높다**는 뜻이고, **엔트로피가 낮으면 불순도가 낮다**는 뜻으로 해석

$$0 \leq E \leq 1$$

$$\boldsymbol{Entorpy} = \sum_{i=1} -\boldsymbol{p_i log_2(p_i)}$$







$$E(A) = -\sum_{k=1}^{m} p_k log_2(p_k)$$

$$= -p(\boldsymbol{red}) log_2\big(p(\boldsymbol{red})\big) - p(\boldsymbol{blue}) log_2\big(p(\boldsymbol{blue})\big)$$

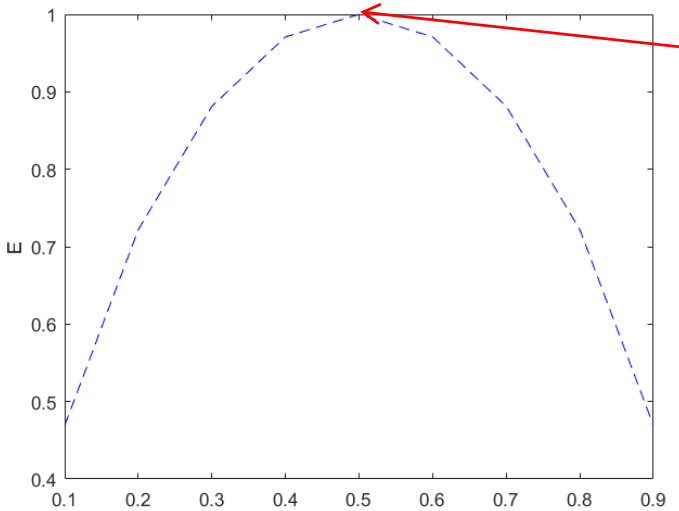
$$= -\frac{10}{16} log_2\left(\frac{10}{16}\right) - \frac{6}{16} log_2\left(\frac{6}{16}\right) \approx 0.95$$

ID3(계속)

- **엔트로피(Entropy)(계속)**
  - 엔트로피가 크다는 것은 평균 정보량이 크다는 정보
  - 대개 사건들이 일어날 확률이 비슷한 경우에 엔트로피가 큼

두 사건이 일어날 비율

{0.9, 0.1}, {0.8, 0.2}, {0.7, 0.3}, {0.6, 0.4}, {0.5, 0.5}, {0.4, 0.6}, {0.3, 0.7}, {0.8, 0.2}, {0.1, 0.9}



두 사건이 일어날 확률이 반반 일 때 엔트로피가 최대치가 됨

어떤 사건이 일어날지 모른다는 불확실성

즉 불확실성이 크면 분류하기 어려워 짐

ID3(계속)

- **정보 획득(Information Gain)**
  - 분할 이전의 엔트로피에서 분할 이후의 엔트로피의 차이
  - 부모노드와 자식노드간의 엔트로피의 차이
  - 결정 트리 알고리즘은 **정보 획득을 최대화하는 방향으로 학습**이 진행
  - **가장 큰 정보 획득을 가지는 속성을 자식 노드로 선택**

$$IG(S, A) = IG(S) - IG(S \mid A)$$

$$IG(Parent, Child) = E(Parent) - E(Parent \mid Child)$$

E(Parent) = 1
E(Parent | A) = 0.7

IG = 0.3

E(Parent) = 1
E(Parent | B) = 0.3

IG = 0.7

정보 획득을 최대화 하기 위해서는
엔트로피의 값이 작아야 함

ID3 생성 예제

기상 조건에 따른 테니스 경기 참가 여부에 대한 의사결정트리 생성

- **주어진 값**
  - 목표
    - 경기 참가여부(O, X)
  - 기상 조건
    - 날씨(맑음, 비, 흐림)
    - 온도(더움, 포근, 서늘)
    - 습도(높음, 정상)
    - 바람(약함, 강함)





	조건 속성				목표
날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D3	흐림	더움	높음	약함	O
D4	비	포근	높음	약함	O
D5	비	서늘	정상	약함	O
D6	비	서늘	정상	강함	X
D7	흐림	서늘	정상	강함	O
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D10	비	포근	정상	약함	O
D11	맑음	포근	정상	강함	O
D12	흐림	포근	높음	강함	O
D13	흐림	더움	정상	약함	O
D14	비	포근	높음	강함	X

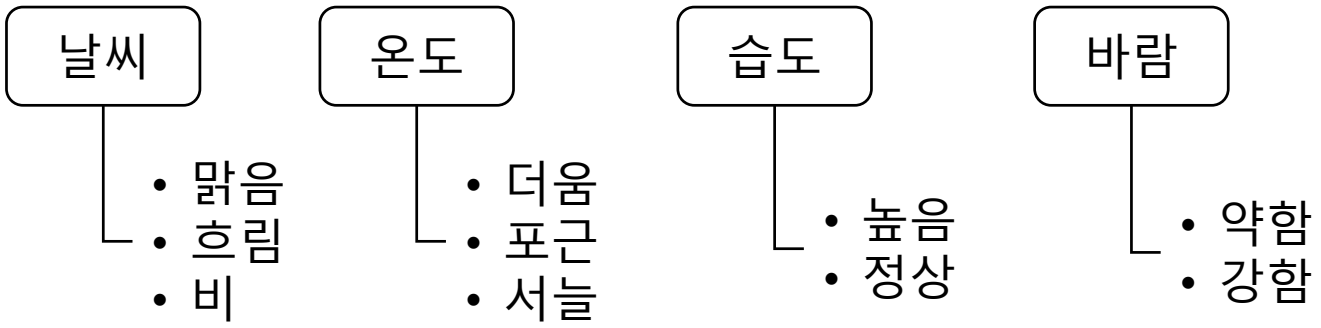
ID3 생성 예제(계속)

- **Step1. 목표 속성에 대한 엔트로피 계산**
  - 경기 참가 여부(O, X)에 대한 엔트로피 계산

$$E(\text{경기}) = \underbrace{-\frac{9}{14}log_2\left(\frac{9}{14}\right)}_{\text{참가(O) 정보량}} \underbrace{-\frac{5}{14}log_2\left(\frac{5}{14}\right)}_{\text{불참가(X) 정보량}} = 0.94$$

참가여부
X
X
O
O
O
X
O
X
O
O
O
O
O
X

- **Step2. 각 속성에 대한 분할 후 엔트로피 계산**

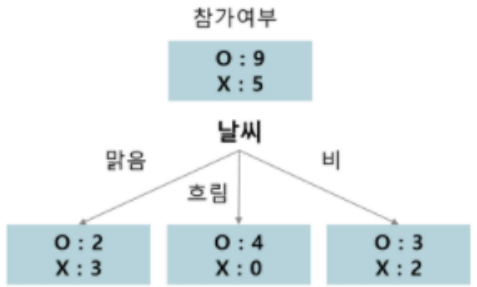


ID3 생성 예제(계속)

- **Step 2.1. 날씨 속성의 엔트로피 계산**

$$E(\text{경기}|\text{날씨}) = p(\text{맑음}) * E(\text{경기}|\text{맑음}) + p(\text{흐림}) * E(\text{경기}|\text{흐림}) + p(\text{비}) * E(\text{경기}|\text{비})$$

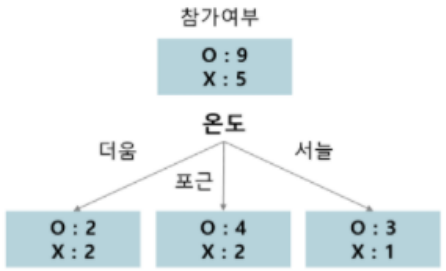
$$\begin{aligned} E(\text{경기}|\text{날씨}) &= \frac{5}{14}\left(-\frac{2}{5}log_2\left(\frac{2}{5}\right)-\frac{3}{5}log_2\left(\frac{3}{5}\right)\right) \\ &+\frac{4}{14}\left(-\frac{4}{4}log_2\left(\frac{4}{4}\right)-\frac{0}{4}log_2\left(\frac{0}{4}\right)\right) \\ &+\frac{5}{14}\left(-\frac{3}{5}log_2\left(\frac{3}{5}\right)-\frac{2}{5}log_2\left(\frac{2}{5}\right)\right) \\ &= 0.694 \end{aligned}$$



- **Step 2.2. 온도 속성의 엔트로피 계산**

$$E(\text{경기}|\text{온도}) = p(\text{더움}) * E(\text{경기}|\text{더움}) + p(\text{포근}) * E(\text{경기}|\text{포근}) + p(\text{서늘}) * E(\text{경기}|\text{서늘})$$

$$\begin{aligned} E(\text{경기}|\text{온도}) &= \frac{4}{14}\left(-\frac{2}{4}log_2\left(\frac{2}{4}\right)-\frac{2}{4}log_2\left(\frac{2}{4}\right)\right) \\ &+\frac{6}{14}\left(-\frac{4}{6}log_2\left(\frac{4}{6}\right)-\frac{2}{6}log_2\left(\frac{2}{6}\right)\right) \\ &+\frac{4}{14}\left(-\frac{3}{4}log_2\left(\frac{3}{4}\right)-\frac{1}{4}log_2\left(\frac{1}{4}\right)\right) \\ &= 0.911 \end{aligned}$$



날씨	온도	참가여부
맑음	더움	X
맑음	더움	X
흐림	더움	O
비	포근	O
비	서늘	O
비	서늘	X
흐림	서늘	O
맑음	포근	X
맑음	서늘	O
비	포근	O
맑음	포근	O
흐림	포근	O
흐림	더움	O
비	포근	X

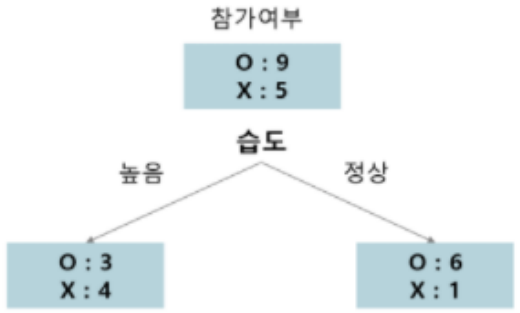
ID3 생성 예제(계속)

- **Step 2.3. 습도 속성의 엔트로피 계산**

$$E(\text{경기}|\text{습도}) = p(\text{높음}) * E(\text{경기}|\text{높음}) + p(\text{정상}) * E(\text{경기}|\text{정상})$$

$$E(\text{경기}|\text{습도}) = \frac{7}{14}\left(-\frac{3}{7}log_2\left(\frac{3}{7}\right) - \frac{4}{7}log_2\left(\frac{4}{7}\right)\right) + \frac{7}{14}\left(-\frac{6}{7}log_2\left(\frac{6}{7}\right) - \frac{1}{7}log_2\left(\frac{1}{7}\right)\right)$$

$$= 0.789$$

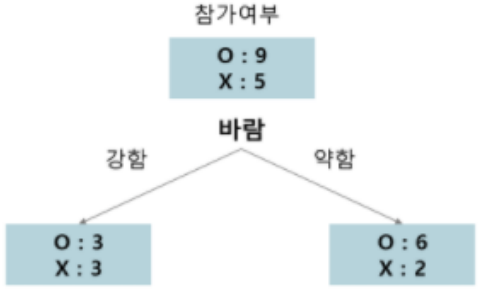


- **Step 2.4. 바람 속성의 엔트로피 계산**

$$E(\text{경기}|\text{바람}) = p(\text{약함}) * E(\text{경기}|\text{약함}) + p(\text{강함}) * E(\text{경기}|\text{강함})$$

$$E(\text{경기}|\text{바람}) = \frac{6}{14}\left(-\frac{3}{6}log_2\left(\frac{3}{6}\right) - \frac{3}{6}log_2\left(\frac{3}{6}\right)\right) + \frac{8}{14}\left(-\frac{6}{8}log_2\left(\frac{6}{8}\right) - \frac{2}{8}log_2\left(\frac{2}{8}\right)\right)$$

$$= 0.892$$



습도	바람	참가여부
높음	약함	X
높음	강함	X
높음	약함	O
높음	약함	O
정상	약함	O
정상	강함	X
정상	강함	O
높음	약함	X
정상	약함	O
정상	약함	O
정상	강함	O
높음	강함	O
정상	약함	O
높음	강함	X

ID3 생성 예제(계속)

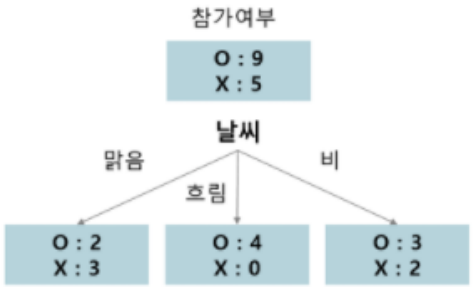
- **Step 3. 각 속성에 대한 정보획득(Information Gain) 계산**

각 속성의 엔트로피

$$\boldsymbol{E}(\text{경기}) = \mathbf{0.94}$$

$$\boldsymbol{E}(\text{경기}|\text{날씨}) = \mathbf{0.694} \qquad \boldsymbol{E}(\text{경기}|\text{온도}) = \mathbf{0.911}$$
$$\boldsymbol{E}(\text{경기}|\text{습도}) = \mathbf{0.789} \qquad \boldsymbol{E}(\text{경기}|\text{바람}) = \mathbf{0.892}$$

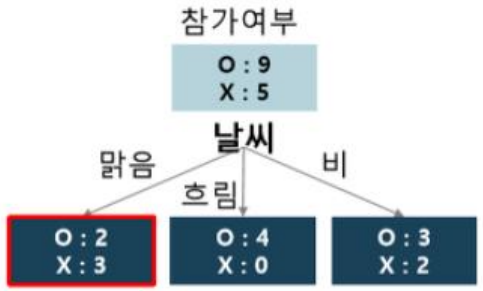
$$IG(\text{경기}, \text{날씨}) = E(\text{경기}) - E(\text{경기}|\text{날씨}) = 0.94 - 0.694 = 0.246$$
$$IG(\text{경기}, \text{온도}) = E(\text{경기}) - E(\text{경기}|\text{온도}) = 0.94 - 0.911 = 0.029$$
$$IG(\text{경기}, \text{습도}) = E(\text{경기}) - E(\text{경기}|\text{습도}) = 0.94 - 0.789 = 0.151$$
$$IG(\text{경기}, \text{바람}) = E(\text{경기}) - E(\text{경기}|\text{바람}) = 0.94 - 0.892 = 0.048$$



ID3 생성 예제(계속)

- **Step 4. 각 리프 노드(Leaf Node)에서 step. 1, 2, 3을 반복**

Step 1. 속성이 맑음 이었을 때 경기 참가(O,X) 엔트로피 계산



날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D11	맑음	포근	정상	강함	O

$$E(\text{경기}) = -\frac{2}{5}log_2\left(\frac{2}{5}\right) - \frac{3}{5}log_2\left(\frac{3}{5}\right) = 0.971$$

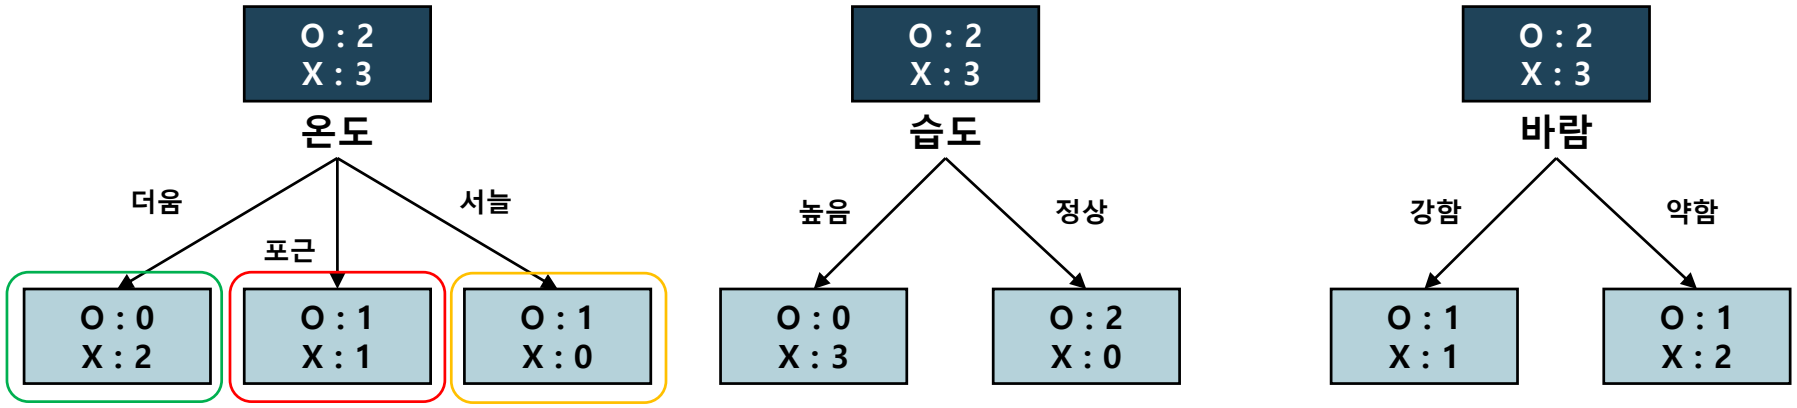
ID3 생성 예제(계속)

Step 2. 나머지 속성에 대한 엔트로피 계산

$$E(\text{경기}|\text{온도}) = \frac{2}{5}\left(-\frac{2}{2}log_2\left(\frac{2}{2}\right)\right) + \frac{2}{5}\left(-\frac{1}{2}log_2\left(\frac{1}{2}\right) - \frac{1}{2}log_2\left(\frac{1}{2}\right)\right) + \frac{1}{5}\left(-\frac{1}{1}log_2\left(\frac{1}{1}\right)\right) = 0.4$$

$$E(\text{경기}|\text{습도}) = \frac{3}{5}\left(-\frac{3}{3}log_2\left(\frac{3}{3}\right)\right) + \frac{2}{5}\left(-\frac{2}{2}log_2\left(\frac{2}{2}\right)\right) = 0$$

$$E(\text{경기}|\text{바람}) = \frac{2}{5}\left(-\frac{1}{2}log_2\left(\frac{1}{2}\right) - \frac{1}{2}log_2\left(\frac{1}{2}\right)\right) + \frac{3}{5}\left(-\frac{1}{3}log_2\left(\frac{1}{3}\right) - \frac{2}{3}log_2\left(\frac{2}{3}\right)\right) = 0.951$$



ID3 생성 예제(계속)

Step 3. 각 속성에 대한 정보획득(Information Gain) 계산

각 속성의 엔트로피

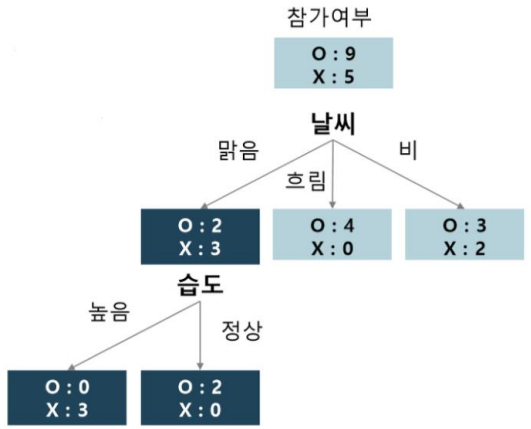
$$\boldsymbol{E}(\text{경기}) = \mathbf{0.971}$$

$$\boldsymbol{E}(\text{경기}|\text{온도}) = \mathbf{0.4} \qquad \boldsymbol{E}(\text{경기}|\text{습도}) = \mathbf{0} \qquad \boldsymbol{E}(\text{경기}|\text{바람}) = \mathbf{0.951}$$

$$IG(\text{경기}, \text{온도}) = E(\text{경기}) - E(\text{경기}|\text{온도}) = 0.971 - 0.4 = 0.571$$

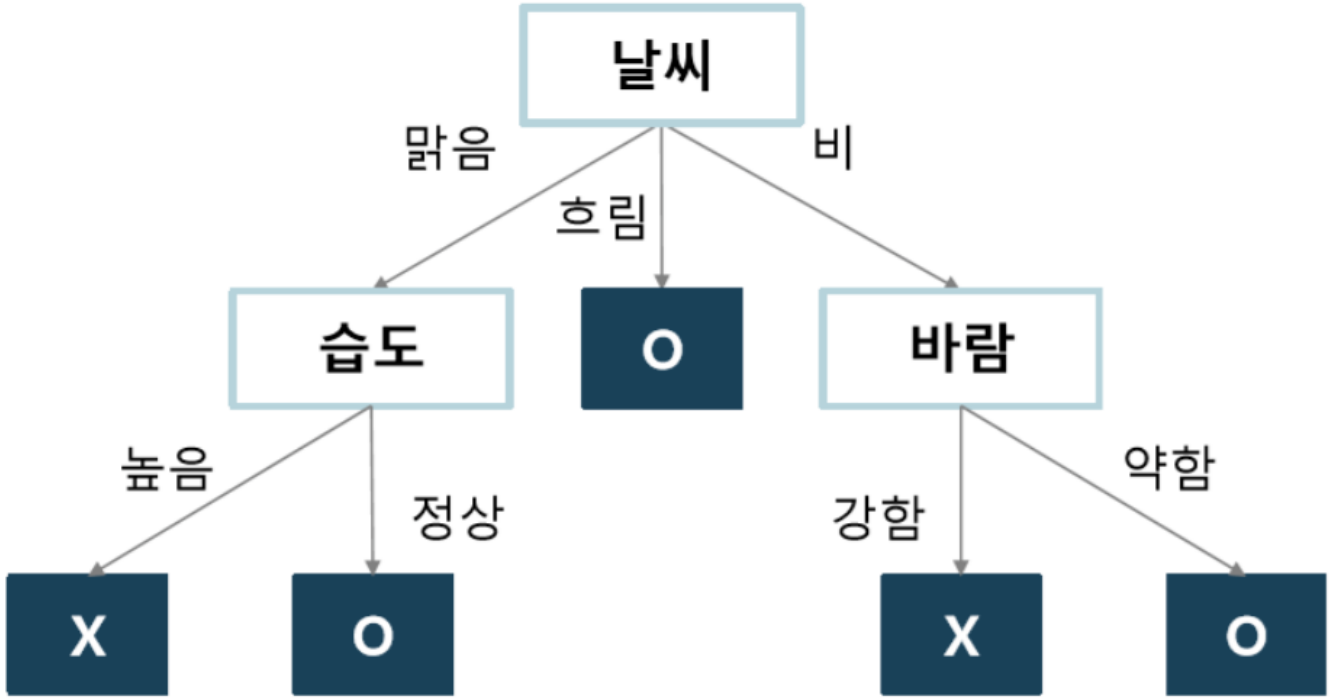
$$IG(\text{경기}, \text{습도}) = E(\text{경기}) - E(\text{경기}|\text{습도}) = 0.971 - 0 = 0.971$$

$$IG(\text{경기}, \text{바람}) = E(\text{경기}) - E(\text{경기}|\text{바람}) = 0.971 - 0.951 = 0.02$$



ID3 생성 예제(계속)

- ID3 최종 생성 결과



지니계수와 CART 알고리즘

- **지니계수(Gini Index)**
  - 불순도를 측정하는 지표, 데이터의 통계적 분산정도를 정량화하여 표현된 값
  - 지니계수은 엔트로피보다 계산이 단순하며 확률이 높을수록 불순도가 빠르게 줄어듬
  - 엔트로피보다 계산 효율성이 높음
  - 주로 CART(Classification and Regression Tree) 알고리즘에서 사용됩니다.

  - 장점
    - 계산이 간단
    - 엔트로피와 결과가 유사
  - 단점
    - 정보 획득(Information Gain)의 직접적인 해석이 어려움
    - 확률이 극단적일때 민감하게 작동

$$G(S) = 1 - \sum_{i=1}^{c} p_i^2$$

S : 현재 노드(데이터 집합)
c : 클래스(종류)의 개수
p_i = 클래스 i가 해당 노드에 속할 확률

지니계수와 CART 알고리즘(계속)

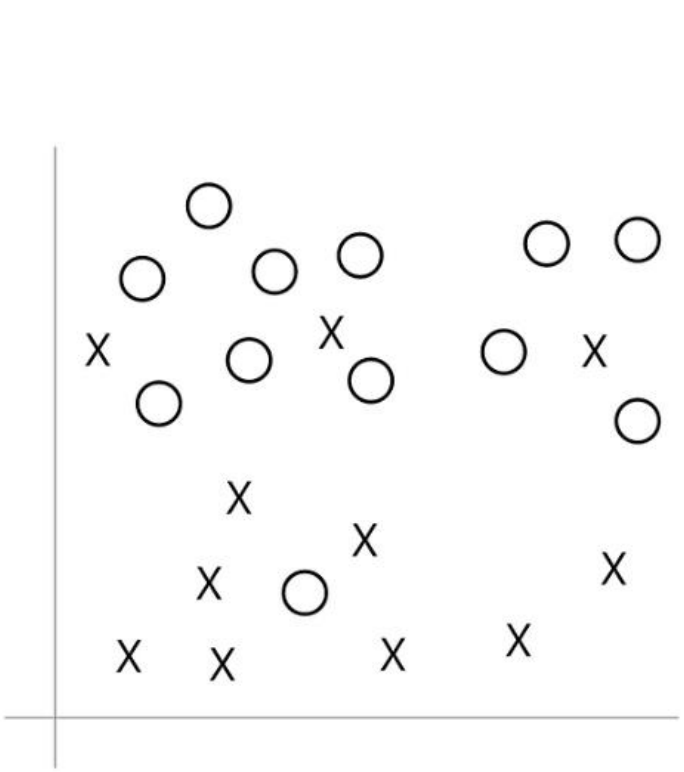
- **CART(Classification and Regression Tree)**
  - 의사결정트리에서 가장 널리 쓰이는 알고리즘
  - 불순도 측정방식
    - Gini 계수: 분류
    - MSE(평균 제곱 오차): 회귀

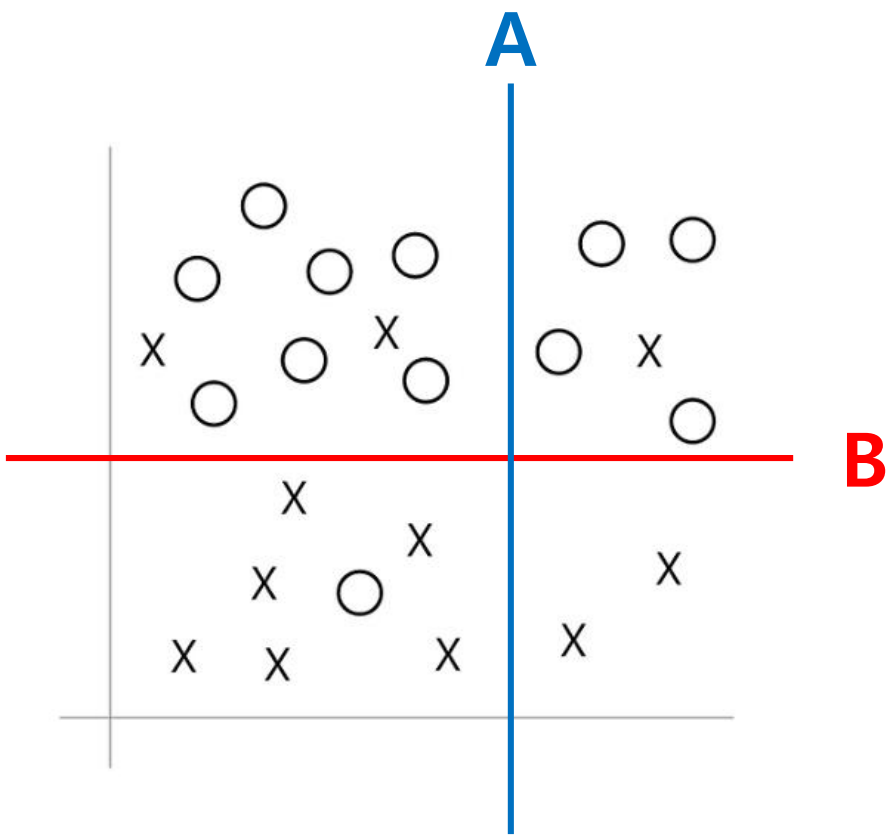
1. 가능한 모든 특성(feature)과 분할 기준(split point)을 탐색

2. 현재 생성된 트리에서 모든 단말 노드는 아래를 반복
- **각 분할 마다 불순도(impurity)감소량을 계산: 지니계수 계산**
- **불순도를 가장 많이 줄이는 분할 기준을 선택**
- **데이터를 둘로 나눔(항상 이진 분할)**

지니계수와 CART 알고리즘(계속)

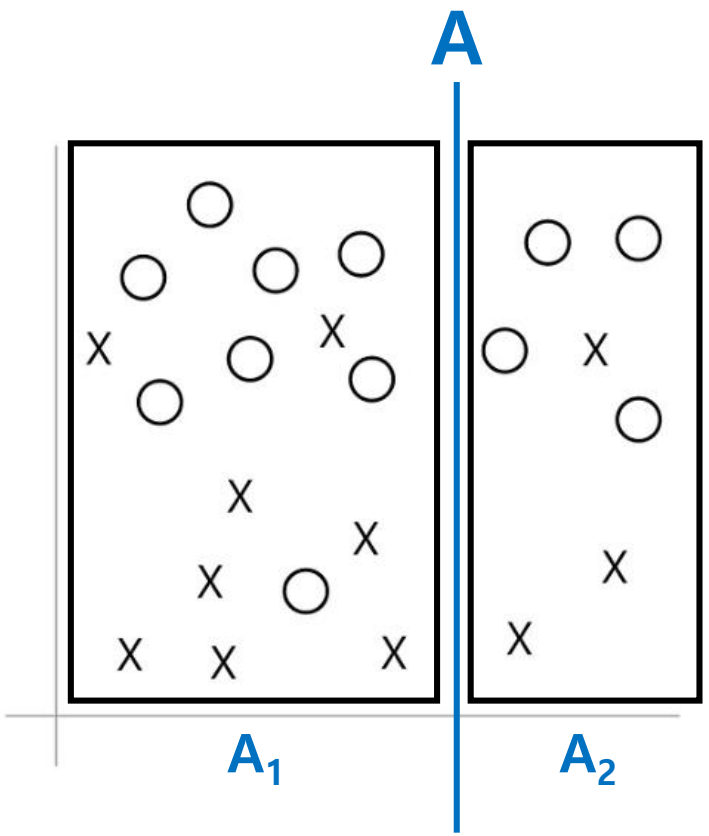
- 현재 주어진 O, X의 상태에서 잘 나눠진 기준 구하기





지니계수와 CART 알고리즘(계속)

- A를 기준으로 분할했을 때 지니계수



O: 8
X: 8

O: 4
X: 3

$$G(S) = 1 - \sum_{i=1}^{c} p_i^2$$

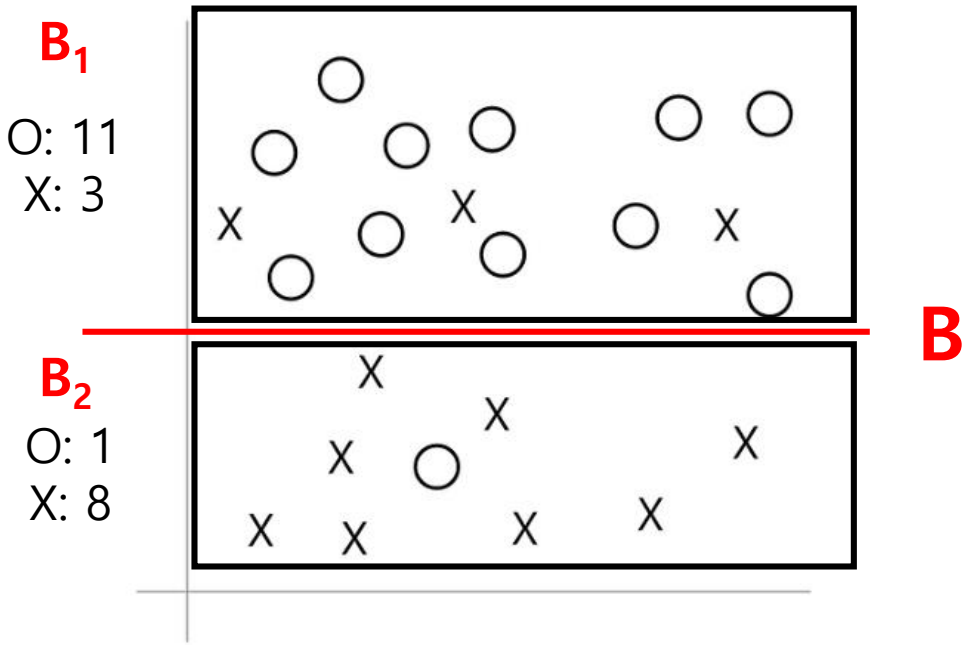
$$G_{A1} = 1 - \left(\left(\frac{8}{16}\right)^2 + \left(\frac{8}{16}\right)^2 \right) = 0.5$$

$$G_{A2} = 1 - \left(\left(\frac{4}{7}\right)^2 + \left(\frac{3}{7}\right)^2 \right) = 0.49$$

$$G_A = \underbrace{\left(\frac{16}{23}\right) * 0.5}_{A_1} + \underbrace{\left(\frac{7}{23}\right) * 0.49}_{A_2} = 0.497$$

지니계수와 CART 알고리즘(계속)

- B를 기준으로 분할했을 때 지니계수



$$G(S) = 1 - \sum_{i=1}^{c} p_i^2$$

$$G_{B1} = 1 - \left(\left(\frac{11}{14}\right)^2 + \left(\frac{3}{14}\right)^2\right) = 0.34$$

$$G_{B2} = 1 - \left(\left(\frac{1}{9}\right)^2 + \left(\frac{8}{9}\right)^2\right) = 0.2$$

$$G_B = \underbrace{\left(\frac{14}{23}\right) * 0.34}_{B_1} + \underbrace{\left(\frac{9}{23}\right) * 0.2}_{B_2} = 0.28$$

의사결정트리의 장단점

- **장점**
  - 이해하기 쉬운 규칙: If ~ Then 형식
  - 분류 예측에 유용
  - 데이터 속성의 중요성 비교 가능
  - 비교적 빠른 생산 속도

- **단점**
  - 연속형 변수 값을 예측할 때 적당하지 않음
  - 트리 모형이 복잡하면 예측력 저하, 해석이 어려워 짐
  - 데이터 변형에 민감하여 안정적이지 않음

요약

- 의사결정트리 개념(Decision Tree)은 데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리 (Tree)기반의 분류 규칙을 만드는 것
- 트리는 노드(Node)로 구성되어 있으며 위치에 따라 부모, 자식, 리프, 형제 , 내부 노드 등으로 이루어짐
- 의사결정트리 생성시 어떤 기준으로 규칙을 만들어야 가장 효율적인 분류가 될 것인가가 알고리즘의 성능을 크게 좌우
- 불순도(Impurity)는 데이터의 복잡성을 의미 하며 ID3에서는 엔트로피(Entropy)를 계산하여 불순도를 측정함
- 정보획득(Information Gain)은 분할 이전의 엔트로피에서 분할 이후의 엔트로피의 차이를 뜻하며 정보획득을 최대로 하는 속성을 기준으로 가지 분할을 함
- 의사결정트리의 장점은 이해하기 쉬운 형태로 생성이 되며 데이터의 중요한 속성이 무엇인지 파악하기 쉬움



강남대학교

KANGNAM UNIVERSITY